

Universidad de Lima
Facultad de Ingeniería
Carrera de Ingeniería de Sistemas



EDGE-MANGO: INFERENCIA MÓVIL DE DAÑO MECÁNICO MEDIANTE DESTILACIÓN DE CARACTERÍSTICAS MULTIMODALES

Trabajo de investigación para optar el Título Profesional de Ingeniero de Sistemas

Gabriel Walter Ysidro Palomino

Código 20222848

Asesor

Lourdes Ramírez Cerna

Lima – Perú

Abril de 2026

Edge-Mango: Inferencia Móvil de Daño Mecánico mediante Destilación de Características Multimodales

Gabriel Walter Ysidro Palomino

20222848@aloe.ulima.edu.pe

Universidad de Lima

Resumen: [En esta sección se describe la esencia, el tema principal del artículo expone las razones de su elección y justifica su importancia, se recomienda un máximo de 300 palabras y la no inclusión de referencias. Incluye la pregunta de investigación planteada, su importancia, la metodología y los principales resultados o hallazgos. Las notas al pie o las obras citadas nunca se enumeran en un resumen.]

Palabras Clave: [Lista de palabras claves que identifican a los temas considerados en el trabajo de investigación. Estas palabras servirán en la búsqueda bibliográfica posterior. En este rubro sólo se pide una lista de palabras sin definiciones (al menos 5).]

Abstract: [Es la traducción al inglés del resumen del ítem anterior].

Keywords: [Listado de palabras clave, en inglés].

1. INTRODUCCIÓN

La apertura de los mercados internacionales ha posicionado a las agroexportaciones como un pilar estratégico para el desarrollo macroeconómico del Perú, representando una fracción mayoritaria de sus exportaciones no tradicionales (Soriano Colchado et al., 2025). Dentro de esta dinámica industrial, el mango (*Mangifera indica* L.) se ha consolidado como un cultivo de altísima relevancia comercial, ubicando al Perú entre los principales proveedores a nivel mundial, abasteciendo a mercados de alta exigencia cualitativa como la Unión Europea y Estados Unidos (Carbajal Fernández & Ramos Cárdenas, 2020). No obstante, sostener la competitividad internacional de este sector exige una cadena de suministro agroindustrial rigurosamente controlada; dado el carácter perecedero del fruto, resulta crítico implementar sistemas de evaluación que garanticen su integridad física e inocuidad desde la etapa de empaque hasta el consumidor final (Mendoza Juárez, 2010).

En este panorama, la capacidad de las empresas procesadoras para mantener estándares de calidad rigurosos es lo que permite el acceso a mercados de alto valor en diferentes partes del mundo (Sanchez, 2023). Sin embargo, la rentabilidad de estas operaciones se ve constantemente amenazada por las mermas generadas durante las fases de postcosecha, donde la integridad física del fruto se convierte en el factor determinante para su aprobación aduanera. Por ejemplo, Truong et al. (2021) describen la caída de los frutos que causan daño mecánico como la mayor causa de pérdida de mangos en el proceso de postcosecha.

El daño mecánico, específicamente en forma de magulladuras o golpes, constituye una de las principales causas de pérdida de valor comercial en la industria frutícola (Liu et al., 2025). Este fenómeno ocurre debido a la aplicación de fuerzas externas, como impactos, vibraciones o compresión excesiva, durante las etapas de recolección, empaque y transporte. A diferencia de las plagas superficiales, el daño mecánico altera la estructura interna de la fruta, comprometiendo su viabilidad antes de que llegue al consumidor final. Según Gámez & Carrera (2022), un golpe superficial en una fruta de 10 centímetros cúbicos puede reducir su

conservación en todas las etapas de la cadena de suministro hasta en un 50%, por lo que garantizar su integridad durante toda la cadena de suministro es crucial.

Desde una perspectiva fisiológica, el daño mecánico desencadena procesos biológicos complejos (como el aumento en la tasa respiratoria, la producción acelerada de etileno y diversas reacciones de oxidación enzimática (Queiroz et al., 2008). Estos eventos provocan un ablandamiento prematuro y alteraciones en la coloración interna de los tejidos. Cabe destacar que estos procesos oxidativos son de carácter irreversible, incluso ante la aplicación de tratamientos químicos mitigantes, como el uso de aceites esenciales (Hao et al., 2025). Por tanto, el mayor desafío radica en que, durante sus etapas tempranas, el daño no presenta síntomas externos evidentes; lo que convierte a las magulladuras en un "defecto latente" que los métodos tradicionales de inspección no logran detectar.

Actualmente, el control de calidad en las empacadoras depende en gran medida de la inspección manual, la cual es subjetiva, lenta y propensa a errores humanos. Aunque existen sistemas de visión computacional basados en imágenes RGB, estos solo son capaces de detectar daños cuando el deterioro ya es evidente en la superficie (Zhang, 2022). Por tanto, existe una brecha tecnológica crítica: la necesidad de un sistema de inspección no destructivo que sea capaz de "ver" bajo la cáscara en tiempo real, sin depender de hardware costoso o infraestructuras de nube que son inasequibles para la operación en campo.

En respuesta a este desafío, la literatura científica reciente ha explorado diversas tecnologías espectrales para la detección de magulladuras. Se ha demostrado que la espectroscopia de infrarrojo cercano (NIR) es una herramienta factible para evaluar el grado de daño de forma no destructiva al analizar la absorción de luz por parte del agua acumulada en los tejidos rotos (Xie et al., 2025). Asimismo, el uso de imágenes térmicas y detección espectral flexible ha permitido la identificación bimodal de daños por frío y golpes en mangos (He et al., 2025). Otros enfoques avanzados incluyen la imagen de fluorescencia hiperespectral, que permite discernir áreas dañadas mediante la firma espectral de la clorofila y otros compuestos (Lee et al., 2025), y la fusión de características espaciales y espectrales para el análisis preciso de magulladuras en frutas delicadas (Shanthini et al., 2026). A nivel computacional, el estado del arte ha migrado hacia el uso de arquitecturas de aprendizaje profundo (*Deep Learning*) optimizadas para la segmentación y clasificación de daños. Se han implementado modelos de segmentación semántica como DeepLabV3+ con cámaras NIR para la detección temprana en peras (Yan et al., 2025), y redes neuronales convolucionales (CNN) personalizadas para la detección sensible al tiempo en ciruelas (Gulzar & Ünal, 2025). Investigaciones en fresas y duraznos también resaltan el uso de redes CNN-BiLSTM y análisis de texturas para identificar el tiempo de almacenamiento tras un golpe ligero (Feng et al., 2025; Sun et al., 2026; Li et al., 2023). Incluso, el uso de clasificadores basados en CNN y análisis local espectral-espacial ha demostrado ser altamente efectivo en cítricos para diferenciar tejidos sanos de magullados (Pourdarbani et al., 2023).

Para hacer frente a esta problemática en el entorno agroexportador peruano, la presente investigación propone el desarrollo de un sistema inteligente de detección temprana de daño mecánico en mangos, diseñado específicamente para operar en condiciones reales de empaque. La solución se fundamenta en la creación de un modelo de aprendizaje profundo capaz de inferir la presencia de lesiones internas (normalmente solo visibles mediante tecnología de infrarrojo cercano) a partir de imágenes capturadas con cámaras de luz visible (RGB) convencionales.

El proyecto abarca desde la construcción de un dataset especializado y curado con imágenes multispectrales de mangos en distintas etapas de daño, hasta la optimización del algoritmo predictivo mediante técnicas de destilación de conocimiento. El resultado final de este proceso

es un modelo ligero y de alta precisión, optimizado para su despliegue en dispositivos móviles convencionales. Este enfoque metodológico garantiza un funcionamiento cien por ciento *offline* en el punto de control agrícola (hardware *Edge*), eliminando la dependencia de infraestructura de servidores o conectividad a internet, y democratizando el acceso a herramientas de control de calidad basadas en visión computacional.

El resto del presente artículo se organiza de la siguiente manera: la Sección 2 presenta los trabajos relacionados al tópico central mediante un análisis estructurado de la literatura técnica; la Sección 3 establece el marco teórico que fundamenta la investigación multimodal. Por su parte, la Sección 4 describe detalladamente la metodología integral aplicada durante todo el proceso de investigación, mientras que la Sección 5 expone los principales resultados experimentales obtenidos. Posteriormente, la Sección 6 discute los hallazgos frente a la literatura actual y las diversas perspectivas del trabajo, mientras que la Sección 7 sintetiza las conclusiones fundamentales derivadas del estudio. Finalmente, la Sección 8 brinda sugerencias y líneas de investigación para el desarrollo de futuros trabajos en esta área del conocimiento.

2. TRABAJOS RELACIONADOS

La evaluación no destructiva de daños mecánicos en frutas ha experimentado una transición significativa en la última década, pasando del análisis químico destructivo a la espectroscopía óptica, y más recientemente, a arquitecturas de aprendizaje profundo en el borde. Sin embargo, la literatura revela una dicotomía persistente: los sistemas precisos dependen de hardware inaccesible, mientras que los sistemas accesibles carecen de precisión para defectos latentes. Para ilustrar esta evolución metodológica, la Tabla 2.1 sintetiza el estado del arte actual, clasificando las investigaciones más relevantes según su dependencia de hardware, rendimiento y viabilidad de despliegue perimetral (*Edge*).

- I. *La dependencia de la Espectroscopia y la visión infrarroja cercana:* El consenso científico estableció de forma temprana que el daño mecánico interno es imperceptible en el espectro visible (RGB) durante las etapas iniciales. Dentro de los enfoques puramente hardware-céntricos (ver Tabla 2.1), trabajos pioneros en la literatura como Rivera et al. (2014) demostraron la viabilidad de la detección temprana de daños mecánicos en mangos usando imágenes hiperespectrales en el rango de los 650 a 1100 nm. combinadas con algoritmos clásicos de ML (como K-NN) que lograron un accuracy del 97.9%. Sin embargo, la limitación de este enfoque radica en su dependencia en la selección manual de características, que luego son procesadas por el modelo de ML. Para superar esta brecha, investigaciones recientes adoptaron el uso de redes neuronales convolucionales (CNN). Por ejemplo, Yao et al. (2024) combinan imágenes hiperespectrales con aprendizaje profundo para detectar el tiempo de almacenamiento de mangos con magulladuras leves. De manera similar, Gulzar et al. (2025) introducen PlmNet, una CNN diseñada específicamente para la detección de magulladuras sensibles al tiempo utilizando imágenes NIR. Castillo-Girones et al. (2024), por su parte, aplican enfoques de Transfer Learning en imágenes espectrales para detectar magulladuras superficiales. No obstante, todos estos trabajos comparten un cuello de botella común para la agricultura peruana: asume la disponibilidad de cámaras NIR costosas en el entorno de inferencia.
- II. *Fusión Multimodal y el problema del despliegue físico:* Para mejorar la robustez, la literatura exploró la fusión de múltiples sensores. He et al. (2025) propusieron una red de aprendizaje ensamblado que fusiona datos de imágenes térmicas y espectrales NIR para clasificar mangos con daños por frío y magulladuras, logrando hasta un 95.24% de

precisión. En una línea similar, Cao et al. (2026) introdujeron el modelo GLS-YOLOv8n, el cual emplea una fusión de imágenes RGB, profundidad (depth) y térmicas para la detección precisa de mangos en entornos complejos. Asimismo, diversificando las modalidades físicas, Wang et al. (2025) propusieron el modelo MECN-net, el cual integra características visuales (RGB), térmicas (TIR) y propiedades dieléctricas capturadas mediante sensoría flexible multiescala, logrando un 98.7% de precisión en la clasificación de daño por frío y magulladuras. Si bien el uso de imágenes multimodales y arquitecturas ligeras eleva el estado del arte en cuanto a precisión y velocidad en entornos controlados, agrava el despliegue en el campo. Como se evidencia en la evaluación de viabilidad de la Tabla 2.1, la exigencia operativa de integrar y sincronizar múltiples cámaras (térmicas o de profundidad) e incluso sensores de contacto de impedancia hace que estas soluciones sean inviables a nivel de infraestructura para la mayoría de plantas empacadoras en Perú.

- III. *El paradigma de la destilación de conocimiento modal cruzado (CMKD)*: Para cerrar la brecha entre la precisión del hardware costoso y la accesibilidad de los sensores RGB, la literatura reciente en visión computacional ha virado hacia la Destilación de Conocimiento (KD). Hu et al. (2020) sentaron un precedente vital al proponer la destilación de redes de segmentación desde modalidades múltiples hacia modalidades simples. En lugar de requerir ambos sensores en inferencia, el modelo “Estudiante” aprende a extraer representaciones robustas usando solo la modalidad de entrada accesible. Avanzando en esta línea, la técnica de destilación de conocimiento desacoplado, propuesta por Zhao et al. (2022) demostró que desacoplar la pérdida de destilación permite a los modelos estudiantes retener mejor el “dark knowledge” del maestro. Para abordar especificar el enmascaramiento superficial (como la cáscara del mango), enfoques recientes como HyperKD introducen la destilación de conocimiento espectral en autoencoders enmascarados, empleando mecanismos de enmascaramiento espacial para forzar a la red a enfocarse en regiones estructuralmente complejas. Este enfoque es metodológicamente correcto a lo que requiere la detección de defectos sutiles en frutas usando RGB.
- IV. *Computación en el Borde e Inferencia Eficiente*: Finalmente, los modelos destilados deben poder ejecutarse en hardware de recursos restringidos. La literatura científica moderna sobre despliegue de modelos destaca que las arquitecturas de la familia YOLO en sus variantes más ligeras (como YOLO-nano o YOLO-tiny), acopladas a metodologías de destilación de conocimiento, representan la solución óptima para aproximar las predicciones de modelos complejos en plataformas perimetrales. Investigaciones recientes han validado este enfoque en entornos agrícolas de alta fricción tecnológica; por ejemplo, y como se destaca en la columna “Arquitectura Algorítmica” de la Tabla 2.1, Fatehi et al. (2025) demostraron que mediante la destilación de conocimiento desde un modelo robusto hacia un estudiante ultraligero, es posible mantener métricas de detección altamente precisas para operaciones en tiempo real en el campo (*in-field*), reduciendo drásticamente la carga computacional requerida. Acoplado a técnicas de cuantización, este flujo de trabajo (*pipeline*) garantiza mantener la fidelidad estructural de la detección, minimizando simultáneamente la latencia de inferencia y la demanda energética en el hardware operativo (*Edge*).

Tabla 2.1

Tabla de Trabajos Relacionados

Referencia	Taxonomía / Enfoque	Entrada (Inferencia)	Arquitectura Algorítmica	Rendimiento	Viabilidad Edge
Rivera et al. (2014)	Hardware-céntrico	HSI (650-1100 nm)	Machine Learning Clásico (K-NN)	97.90%	Nula
Yao et al. (2024)	Hardware-céntrico	HSI	Deep Learning (CNN)	Alta precisión	Nula
Gulzar et al. (2025)	Hardware-céntrico	NIR	CNN Especializada (PlmNet)	Sensible al tiempo	Baja
Castillo-Girones et al. (2024)	Hardware-céntrico	VIS-NIR	ResNet - HSCNN	F1 Score: 81%	Baja
He et al. (2025)	Fusión Sensorial	Térmico + NIR	Ensamble DL Multimodal	95.24%	Nula
Cao et al. (2026)	Fusión Sensorial	Térmico + RGB	GLS-YOLOv8n	97.2% AP	Media
Wang et al. (2025)	Fusión Sensorial	RGB + Térmico + Sensores Dieléctricos	MECN-Net	98.5% F1 Score	Nula
Hu et al. (2020)	Transferencia (CMKD)	Simple (Mono)	Destilación (Multi a Mono-modal)	Retención de features	Media
Zhao et al. (2022)	Transferencia (CMKD)	Simple (Mono)	Destilación Desacoplada	Mayor retención	Alta

Fatehi et al. (2025)	Transferencia y Edge AI	RGB	Destilación a YOLOv9-tiny	Alta precisión RT (Real-Time)	Muy Alta
----------------------	-------------------------	-----	---------------------------	-------------------------------	----------

A pesar de la evolución sostenida en las técnicas de evaluación no destructiva de daños mecánicos, la revisión de la literatura actual resumida en la Tabla 2.1 presenta una profunda dicotomía entre la capacidad predictiva algorítmica y su viabilidad operativa en entornos agrícolas de producción. Por un lado, los enfoques de alta precisión (Yao et al., 2024; Gulzar et al., 2025; He et al., 2025) logran identificar lesiones celulares latentes, pero imponen una barrera de entrada prohibitiva para la industria al depender intrínsecamente del uso de costosos sensores infrarrojos, térmicos o hiperespectrales durante la fase de inferencia; por otro lado, si bien el paradigma de la Destilación de Conocimiento Modal Cruzado (CMKD) ha demostrado la viabilidad teórica de transferir representaciones complejas hacia sensores accesibles (Hu et al., 2020; Zhao et al., 2022), dichas investigaciones empíricas se han confinado casi en su totalidad a entornos de servidor con alta capacidad de cómputo, ignorando las fricciones de latencia y consumo energético inherentes al despliegue perimetral (*Edge Computing*). En consecuencia, la brecha crítica que la presente investigación busca cerrar es la inexistencia de un framework MLOps *End-to-End* que logre independizar la detección de defectos orgánicos de los equipos de alto costo, proponiendo una arquitectura asimétrica donde toda la complejidad sensorial (NIR) y de extracción de características (redes maestras como ConvNeXt) se restrinja exclusivamente a la fase de entrenamiento, dotando así a un modelo estudiante altamente optimizado (YOLO en su variante Nano) de la capacidad de retener el "conocimiento oscuro" infrarrojo para ejecutar inferencias precisas utilizando únicamente cámaras RGB comerciales de forma cien por ciento *offline*.

3. MARCO TEÓRICO

El presente marco teórico establece los fundamentos conceptuales y matemáticos que sustentan la detección temprana de anomalías poscosecha mediante inteligencia artificial en el borde (Edge AI). Esta investigación se apoya en la convergencia de tres ejes teóricos: la fisiopatología vegetal del daño mecánico, la teoría de extracción de características multimodales mediante redes neuronales convolucionales asimétricas (ConvNeXt y arquitecturas YOLO), y el paradigma matemático de la Destilación de Conocimiento Modal Cruzado (CMKD). A través de estas "lentes conceptuales", se explica cómo el conocimiento extraído del espectro no visible puede ser parametrizado y transferido a un modelo ligero para su ejecución en entornos de restricciones computacionales.

1. El Daño Mecánico (Objeto de Detección)

En la fisiología poscosecha, el daño mecánico se define operacionalmente como la disrupción física de la integridad celular y tisular de un fruto debido a fuerzas de compresión, impacto o vibración. Desde una perspectiva bioquímica, esta energía cinética provoca la ruptura de las membranas vacuolares, induciendo la mezcla de la enzima polifenol oxidasa (PPO) con sustratos fenólicos endógenos (Queiroz et al., 2008). Esta reacción cataliza el pardeamiento enzimático interno.

El desafío para la visión computacional radica en la naturaleza ópticamente latente de este fenómeno: el daño tisular inicial ocurre en las capas de la pulpa subyacente y tarda días en manifestarse como necrosis en la epidermis exterior, volviéndolo imperceptible para el ojo humano y los sensores ópticos estándar durante la etapa crítica de empaque.

2. Características Multimodales en Visión Computacional

La multimodalidad se define como la captura y parametrización de información proveniente de múltiples distribuciones sensoriales (espectros de luz). En este modelo conceptual, se operacionalizan dos canales ópticos:

- **Espectro Visible (RGB):** Representa las matrices de píxeles capturadas en el rango de longitudes de onda de 400 a 700 nm. Permite la extracción de tensores relacionados con características geométricas, colorimetría superficial y texturas de la cáscara. Su principal restricción teórica es la nula capacidad de penetración tisular frente al pardeamiento latente.
- **Espectro Infrarrojo Cercano (NIR - Específicamente a 850nm):** Opera basándose en la teoría de la espectroscopía de absorción. A una longitud de onda de 850nm, la luz fotónica interactúa directamente con los enlaces moleculares O-H (agua) y C-H (carbohidratos) del tejido interno. Al romperse las membranas por daño mecánico, la redistribución de fluidos y los cambios en la dispersión de la luz generan una firma reflectiva (gradiente de intensidad) que los sensores infrarrojos captan, convirtiendo anomalías anatómicas internas en variaciones medibles a nivel de píxel antes de la oxidación superficial.

3. Modelos de Aprendizaje Profundo

La arquitectura propuesta requiere el entrenamiento de dos topologías neuronales convolucionales (CNN) que cumplen roles asimétricos:

- **Modelo Maestro (Teacher - ConvNeXt)** Es una arquitectura fundamentada en el diseño de redes convolucionales puras que incorporan principios inductivos de los Vision Transformers (ViTs) (Liu et al., 2022). Se caracteriza por el uso intensivo de convoluciones depthwise con kernels de gran tamaño (ej. 7x7), activaciones GELU y normalización de capas reducidas. En el contexto de esta investigación, ConvNeXt se operacionaliza como el modelo de alta capacidad paramétrica que opera sobre el espectro privilegiado (NIR). Su función es construir mapas de características (feature maps) ricos y altamente dimensionales que codifican la ubicación exacta y severidad del daño celular subyacente.
- **Modelo Estudiante (Student - YOLO Nano):** La familia You Only Look Once (YOLO) representa el paradigma de detección de objetos de un solo disparo (one-stage detectors), calculando probabilidades de clase y regresión de cajas delimitadoras simultáneamente. La topología "Nano" (como YOLOv8n o YOLOv9t) basa su teoría en la reducción drástica de Operaciones de Punto Flotante por Segundo (FLOPs) mediante cuellos de

botella cruzados y capas convolucionales separables (Jocher et al., 2023). Su función operacional es actuar como el modelo desplegable que recibe únicamente la entrada RGB y deduce la ubicación del daño basándose en el conocimiento transferido.

4. Destilación de Conocimiento Modal Cruzado (CMKD)

La Destilación de Conocimiento Modal Cruzado es el marco matemático que permite a un modelo estudiante aprender representaciones robustas en una modalidad empobrecida (RGB) guiándose por un maestro entrenado en una modalidad rica (NIR) (Gupta et al., 2016).

En lugar de entrenar al estudiante únicamente con Hard Labels (las coordenadas binarias manuales del defecto), se aprovecha el "Dark Knowledge" (las distribuciones de probabilidad relativas y los mapas de características latentes) que produce el maestro.

Para forzar al Modelo Estudiante a emular la extracción de características infrarrojas usando solo píxeles RGB, se diseña una Función de Pérdida Personalizada (Custom Loss). Esta función minimiza simultáneamente el error de predicción contra la realidad (L_{task}) y la divergencia estadística entre las activaciones internas de ambos modelos (L_{KD}):

$$L_{total} = \alpha L_{task} + \beta L_{KD}$$

Donde α y β son hiperparámetros que estabilizan la convergencia. El componente L_{KD} (frecuentemente calculado mediante la Divergencia de Kullback-Leibler o el Error Cuadrático Medio de los mapas de atención espacial) penaliza matemáticamente a la red YOLO si las características que extrae de la cáscara (RGB) no logran correlacionarse con el área de daño interno que ConvNeXt detecta mediante el sensor de 850 nm.

5. Computación en el Borde (Edge Computing) e Inferencia Eficiente

El paradigma de Edge AI estipula que el procesamiento de inferencia de una red neuronal debe trasladarse desde servidores centralizados (Cloud) hacia nodos de hardware perimetrales cercanos a la fuente de datos (ej. cámaras en la faja transportadora, o dispositivos móviles).

Teóricamente, esto resuelve la latencia de red y elimina la dependencia de conectividad constante. Para que un modelo predictivo como YOLO opere dentro de las restricciones de memoria RAM y potencia de cómputo (TDP) del hardware perimetral, se aplica la Cuantización. Este proceso algorítmico reduce la precisión matemática de los pesos tensoriales del modelo, típicamente pasando de representaciones de coma flotante de 32 bits (Float32) a enteros de 8 bits (INT8). La literatura actual demuestra que modelos destilados y cuantizados pueden retener una precisión estructural equivalente a la del modelo maestro, disminuyendo radicalmente el consumo energético y la latencia (Fatehi et al., 2025).

4. METODOLOGÍA

4.1. Diseño Metodológico y Escenario de Aplicación

El presente estudio propone un marco metodológico cuantitativo y experimental para el desarrollo y aplicación de la Destilación de Conocimiento Modal Cruzado (CMKD, por sus siglas en inglés), abarcando un flujo de trabajo integral (*End-to-End MLOps*) desde la ingeniería del *dataset* hasta su despliegue *offline* en el borde (*Edge Computing*). El objetivo central es cuantificar la eficacia en la transferencia de representaciones latentes desde un Modelo Maestro de alta capacidad paramétrica (entrenado bajo condiciones de laboratorio con acceso a modalidades ópticas fusionadas) hacia un Modelo Estudiante de arquitectura ligera que operará exclusivamente con el espectro visible en la detección del daño mecánico en 50 unidades de mangos.

La experimentación y el entrenamiento computacional se llevarán a cabo en el Laboratorio de Inteligencia Artificial de la carrera de Ingeniería de Sistemas de la Universidad de Lima. Posteriormente, la validación final se ejecutará en un entorno móvil simulando las restricciones operativas de una empaadora agrícola comercial, mitigando así la brecha entre el rendimiento teórico en servidores y la viabilidad de inferencia en escenarios reales de exportación.

4.2. Materiales y Equipamiento Técnico

Para soportar cada fase de la investigación, se definió la siguiente arquitectura de *hardware* y *software*:

- **Adquisición Perimetral (Sensores):** Una Arducam 8MP con sensor IMX219 RGB conectada por USB y un módulo de cámara Raspberry Pi NoIR v2 (sin filtro infrarrojo), equipado con iluminación LED IR calibrada específicamente a una longitud de onda de 850nm para penetrar el tejido frutal.
- **Orquestación IoT:** Un microcontrolador Raspberry Pi Zero 2W, encargado de sincronizar los disparos simultáneos de ambos sensores ópticos.
- **Infraestructura de Entrenamiento:** Una estación de trabajo equipada con una GPU NVIDIA RTX A5000 (24 GB de VRAM), necesaria para procesar las operaciones de punto flotante de la arquitectura ConvNeXt.
- **Despliegue Edge:** Un dispositivo móvil inteligente Xiaomi 14T, equipado con un procesador MediaTek Dimensity 8300 Ultra, utilizado para la validación de latencia *offline*.
- **Stack de Software algorítmico:** Entornos de desarrollo apoyados por herramientas agénticas y de orquestación en la nube (AWS, Opencode), implementando los frameworks nativos de Meta (para ConvNeXt) y Ultralytics (para YOLOv8).


4.3. Creación y Preprocesamiento del Dataset

La viabilidad del enfoque CMKD depende críticamente de la alineación espacial de los datos. Para garantizar la calidad del Ground Truth, el procedimiento de captura se aisló dentro de una "caja negra" (un entorno de iluminación estrictamente controlada). Esto eliminó la contaminación lumínica ambiental, permitiendo que la cámara NoIR capturara exclusivamente la reflectancia de los emisores de 850nm interactuando con el daño mecánico celular interno de las frutas.

Dado que las cámaras RGB y NIR tienen lentes físicamente separados, capturan la fruta desde perspectivas ligeramente distintas. Para corregir este paralaje, se aplicó una transformación de perspectiva mediante una matriz de homografía. Este algoritmo matemático forma proyectivamente una imagen sobre la otra, logrando que el píxel (X,Y) en la imagen RGB corresponde anatómicamente al mismo espacio físico celular en la imagen infrarroja. El resultado es un dataset multimodal donde ambas distribuciones espectrales están perfectamente alineadas. En la Figura 4.1, se observa el proceso de la creación del dataset desde la captura de imágenes de los mangos hasta la transformación con la matriz de homografía.

Figura 4.1


Proceso de Creación del Dataset




4.4. Entrenamiento del Modelo Maestro y Estudiante

El flujo algorítmico se divide en dos fases asimétricas, detalladas en la Figura 4.2:

1. **Entrenamiento del Maestro (ConvNeXt):** Este modelo se entrena utilizando la técnica de *Early Fusion*. Los tensores de entrada se apilan en 4 canales (R, G, B + NIR de 850nm). Gracias a la alta dimensionalidad de ConvNeXt, el modelo extrae mapas de características profundos (*feature maps*) que correlacionan el aspecto físico de la cáscara con el daño interno latente detectado por el infrarrojo.
2. **Destilación hacia el Estudiante (YOLOv8-nano):** Se instancia la arquitectura ultraligera YOLOv8-nano limitando su entrada a solo 3 canales (RGB). Durante su entrenamiento, se emplea una Función de Pérdida Personalizada (*Custom Loss*). Esta función no solo evalúa el error de predicción contra las etiquetas manuales (*Hard Labels*), sino que penaliza matemáticamente las discrepancias funcionales entre las capas ocultas del estudiante y el "conocimiento oscuro" (*Dark Knowledge*) extraído por ConvNeXt. Esto fuerza a la red YOLO a inferir la ubicación del daño subsuperficial basándose únicamente en correlaciones del espectro visible.

Figura 4.2*Proceso de Entrenamiento Multimodal***4.5. Exportación y Despliegue en el Dispositivo Edge**

Una vez que el modelo YOLOv8-nano ha convergido y asimilado el comportamiento del maestro, se procede a su optimización para hardware restringido. Se aplica una técnica de Cuantización Post-Entrenamiento (PTQ, por sus siglas en inglés), que reduce la precisión matemática de los pesos tensoriales de coma flotante de 32 bits (Float32) a enteros de 8 bits (INT8). El modelo resultante se exporta a un formato serializado compatible con el entorno móvil (ej. TFLite o formato nativo de Android) y se implementa en el procesador MediaTek del Xiaomi 14T para su ejecución totalmente *offline*. Se detalla el proceso del despliegue Edge en la Figura 4.3.

Figura 4.3*Proceso de Despliegue Edge*

Para determinar el éxito de la transferencia de conocimiento y la viabilidad del sistema en el entorno de producción, la validación se dividirá en dos dimensiones evaluativas: rendimiento predictivo (algorítmico) y rendimiento operativo (*Hardware Edge*).

A. Evaluación del Rendimiento Predictivo (Computer Vision) El desempeño de clasificación y detección de cajas delimitadoras (*Bounding Boxes*) de ambos modelos (Maestro vs. Estudiante) se someterá a validación cruzada utilizando las siguientes métricas estándar de la industria:

- **Mean Average Precision (mAP@0.5 y mAP@0.5:0.95):** Servirá como el indicador principal para evaluar la exactitud en la localización del daño mecánico. Se analizará cuánta precisión retiene el Estudiante destilado frente al Maestro multimodal.
- **Precisión (Precision) y Exhaustividad (Recall):** Medirán la proporción de falsos positivos (fruta sana clasificada como dañada) y falsos negativos (daño latente no detectado por depender solo del RGB).
- **F1-Score:** Proporcionará una media armónica entre precisión y exhaustividad, vital para evaluar el modelo ante posibles desbalances en las clases de severidad del defecto.

B. Evaluación del Rendimiento Operativo (MLOps en Edge) Para validar que el modelo estudiante cumple con los requerimientos de la agroindustria, su ejecución en el dispositivo móvil Xiaomi 14T será parametrizada mediante:

- **Latencia de Inferencia:** Tiempo transcurrido (en milisegundos) desde que el dispositivo captura el *frame* RGB hasta que emite la predicción.
- **Throughput (FPS):** Cantidad de cuadros por segundo que el procesador móvil es capaz de analizar de manera sostenida, asegurando que cumple con los requerimientos de velocidad de una faja transportadora.
- **Reducción de Huella Computacional:** Comparativa del tamaño en disco (MB) y requerimientos de memoria RAM entre el modelo ConvNeXt base y el YOLOv8-nano cuantizado en INT8

Finalmente, se aplicarán pruebas de significancia estadística (como la prueba *t* de Student) sobre las métricas predictivas para confirmar científicamente que la diferencia de exactitud entre usar costosas cámaras NIR (Maestro) y cámaras RGB comerciales destiladas (Estudiante) no compromete operativamente el control de calidad previo a la exportación.

5. RESULTADOS

[Los resultados pueden ir por separado o integrados en la sección de discusión, bajo el título Resultados y Discusión. Se recomienda que, si tiene una sección de Resultados por separado, éstos deben presentarlos con poca o ninguna interpretación o discusión. Colocar los resultados más representativos, organizarlos en una secuencia que resalte las respuestas a los objetivos, hipótesis o preguntas que usted mismo establezca al comienzo del documento.]

6. DISCUSIÓN

[En esta sección debe expresar su punto de vista sin una plantilla específica, pero debe ser convincente y creíble al mismo tiempo. En la redacción trate de ser constructivo cuando discuta lo que cree que son las limitaciones de los demás con respecto a los resultados obtenidos.]

7. CONCLUSIONES

[Análisis crítico y objetivo de los resultados obtenidos en comparación con los resultados esperados, explicando por qué y que problemas quedan pendientes.]

8. TRABAJOS FUTUROS

[Sugerencias para las siguientes etapas de implementación y nuevos trabajos de investigación].

REFERENCIAS

- Cao, W., Zhang, Z., Wang, Z., Wei, A., Chen, Q., Igathinathane, C., Zhang, F., Abdelhamid, M. A., Ye, D., & Ampatzidis, Y. (2026). GLS-YOLOv8n: A lightweight ‘Guiqi’ mango detection model via RGB-depth-thermal image fusion. *Computers and Electronics in Agriculture*, 242, 111355. <https://doi.org/10.1016/j.compag.2025.111355>
- Carbajal Fernández, A. M., & Ramos Cárdenas, J. M. (2020). *Factores determinantes en las exportaciones peruanas de mango a Países Bajos durante el periodo 2013 - 2018* [Tesis de Licenciatura, Universidad Peruana de Ciencias Aplicadas]. Repositorio Académico UPC. <https://repositorioacademico.upc.edu.pe/handle/10757/651623>
- Castillo-Girones, S., Van Belleghem, R., Wouters, N., Munera, S., Blasco, J., & Saeys, W. (2024). Detection of subsurface bruises in plums using spectral imaging and deep learning with wavelength selection. *Postharvest Biology and Technology*, 207, 112615. <https://doi.org/10.1016/j.postharvbio.2023.112615>
- Fatehi, F., Bagherpour, H., & Amiri Parian, J. (2025). Enhancing the performance of YOLOv9t through a knowledge distillation approach for real-time detection of bloomed damask roses in the field. *Smart Agricultural Technology*, 10, 100280. <https://doi.org/10.1016/j.atech.2025.100280>
- Feng, R., Han, X., Lan, Y., Gou, X., Zhang, J., Wang, H., Zhao, S., & Kong, F. (2025). Detection of early subtle bruising in strawberries using VNIR hyperspectral imaging and deep learning. *Vibrational Spectroscopy*, 138, 103786. <https://doi.org/10.1016/j.vibspec.2025.103786>
- Gulzar, Y., & Ünal, Z. (2025). Time-sensitive bruise detection in plums using PlmNet with transfer learning. *Procedia Computer Science*, 257, 127–132. <https://doi.org/10.1016/j.procs.2025.03.019>
- Gupta, S., Hoffman, J., & Malik, J. (2016). Cross-modal distillation for supervision transfer. En *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 2827-2836). IEEE. <https://doi.org/10.1109/CVPR.2016.309>
- He, W., Huang, W., Popovic, T., Zhu, Z., & Zhang, X. (2025). Improving mango cold-damage and bruise detection using thermal imaging and flexible spectral sensing. *Food Control*, 172, 111163. <https://doi.org/10.1016/j.foodcont.2025.111163>
- Hu, M., Maillard, M., Zhang, Y., Ciceri, T., La Barbera, G., Bloch, I., & Gori, P. (2020). Knowledge distillation from multi-modal to mono-modal segmentation networks. En

International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI) (pp. 772–781). Springer.

Lee, A., Baek, I., Kim, J., Hong, S.-J., & Kim, M. S. (2025). Deep learning approaches for bruised mandarin orange classification by fluorescence hyperspectral imaging. *Postharvest Biology and Technology*, 230, 113724. <https://doi.org/10.1016/j.postharvbio.2025.113724>

Li, B., Zou, J.-p., Yin, H., Liu, Y.-d., Zhang, F., & Ou-yang, A.-g. (2023). Detection of the storage time of light bruises in yellow peaches based on spectrum and texture features of hyperspectral image. *Journal of Chemometrics*, 37(11), e3516. <https://doi.org/10.1002/cem.3516>

Liu, F., Hai, M., Mei, B., Yi, L., & Xie, S. (2025). How does mechanical damage affect the preservability of postharvest fruits and vegetables? *LWT*, 237, 118781. <https://doi.org/10.1016/j.lwt.2025.118781>

Liu, Z., Mao, H., Wu, C. Y., Feichtenhofer, C., Darrell, T., & Xie, S. (2022). A ConvNet for the 2020s. En *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 11976–11986). IEEE. <https://doi.org/10.1109/CVPR52688.2022.01167>

Mendoza Juárez, M. J. (2010). *Optimización de los métodos de gestión aplicados a las operaciones de empresas agroexportadoras* [Tesis de Licenciatura, Universidad de Piura]. Repositorio Institucional Pirhua. <https://pirhua.udep.edu.pe/backend/api/core/bitstreams/172313b8-3d95-4875-92e1-927e235dbbba/content>

Pourdarbani, R., Sabzi, S., Dehghankar, M., Rohban, M. H., & Arribas, J. I. (2023). Examination of lemon bruising using different CNN-based classifiers and local spectral-spatial hyperspectral imaging. *Algorithms*, 16(2), 113. <https://doi.org/10.3390/a16020113>

Queiroz, C., Mendes Lopes, M. L., Fialho, E., & Valente-Mesquita, V. L. (2008). Polyphenol oxidase: Characteristics and mechanisms of browning control. *Food Reviews International*, 24(4), 361–375. <https://doi.org/10.1080/87559120802089332>

Rivera, N. V., Gómez-Sanchis, J., Chanona-Pérez, J., Carrasco, J. J., Millán-Giraldo, M., Lorente, D., Cubero, S., & Blasco, J. (2014). Early detection of mechanical damage in mango using NIR hyperspectral images and machine learning. *Biosystems Engineering*, 122, 91–98. <https://doi.org/10.1016/j.biosystemseng.2014.03.009>

Sánchez Burgos, K. F. (2023). *El impacto de las nuevas tecnologías aplicadas al desarrollo exportador de mangos frescos en la región costera del Perú durante los últimos 10 años* [Tesis de Licenciatura, Universidad de Lima]. Repositorio Institucional ULima. <https://hdl.handle.net/20.500.12724/18846>

Shanthini, K. S., George, S. N., Francis, J., & George, S. (2026). SS-CNN BruiseFinder: Hyperspectral imaging and CNN-driven spatial-spectral fusion for non-destructive plum bruise analysis. *Food Control*, 182, 111870. <https://doi.org/10.1016/j.foodcont.2025.111870>

Soriano Colchado, J. L., Soriano Colchado, A. M., Solano Gaviño, J. C., & Barraza Jáuregui, G. (2025). Desempeño competitivo de las exportaciones de frutas y hortalizas en la región La Libertad, Perú. *Manglar*, 22(4), 495–502. <https://doi.org/10.57188/manglar.2025.050>

- Sun, C., Zhang, L., Zhai, L., Shen, T., Cai, J., Zou, X., & Guo, Z. (2026). Automatic early bruise detection in strawberry fruit by hyperspectral imaging and deep learning techniques. *Postharvest Biology and Technology*, 232, 113966. <https://doi.org/10.1016/j.postharvbio.2025.113966>
- Wang, Y., Li, Y., Chen, R., Zhang, X., Polovka, M., & Tobolková, B. (2025). A mango cold damage bruise detection model based on multiscale flexible sensing and multimodal fusion learning. *Journal of Food and Nutrition Research*, 64(4), 309-318. <https://doi.org/10.64122/GTDF1855>
- Xie, Y., Xi, Q., Han, X., Li, Z., Li, G., Wang, H., Liu, M., & Zhao, J. (2025). A feasibility study on improving the non-destructive detection accuracy of Huping jujube (*Ziziphus jujuba* Mill. cv. Huping) damage degree using near infrared spectroscopy. *Vibrational Spectroscopy*, 139, 103826. <https://doi.org/10.1016/j.vibspec.2025.103826>
- Yan, C., Zhao, H., Zhu, D., Yang, Y., Xing, R., Tang, Q., & Liao, J. (2025). Detection of early bruising in ‘Huangguan’ pear based on MCC-DeepLabV3+ model. *INMATEH - Agricultural Engineering*, 76(2). <https://doi.org/10.35633/inmateh-76-23>
- Yao, C., Su, C.-t., Zou, J.-p., Ou-yang, S.-t., Wu, J., Chen, N., de Liu, Y., & Li, B. (2024). Detection storage time of mangoes after mild bruise based on hyperspectral imaging combined with deep learning. *Journal of Chemometrics*, e3559. <https://doi.org/10.1002/cem.3559>
- Yu, J., Cao, S.-Y., Zhang, R., Zhang, C., Yu, Z., Chen, S., Yang, B., & Shen, H.-L. (2025). SSHNet: Unsupervised Cross-modal Homography Estimation via Problem Reformulation and Split Optimization. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 16685–16694).
- Zhang, P., Shen, B., Ji, H., Wang, H., Liu, Y., Zhang, X., & Ren, C. (2022). Nondestructive prediction of mechanical parameters to apple using hyperspectral imaging by support vector machine. *Food Analytical Methods*, 15, 1397–1406. <https://doi.org/10.1007/s12161-021-02201-2>
- Zhao, B., Cui, Q., Song, R., Qiu, Y., & Liang, J. (2022). Decoupled knowledge distillation. En *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 11953–11962). IEEE. <https://doi.org/10.1109/CVPR52688.2022.01165>